

Проект: Программа для выявления заимствований в исходном коде и отчётах студенческих работ.

Описание:

Программа представляет собой детектор заимствований в студенческих работах. Преподаватель загружает в неё архив со всей сдачей группы, где лежат и исходный код, и отчёты по лабораторным работам в форматах DOCX и PDF. Программа сравнивает каждую работу с каждой и выдаёт отчёт по всем парам «кто с кем». Обычные сервисы проверки проверяют только текст и легко обманываются, если в коде переименовать переменные или поменять функции местами.

Цель проекта: сделать инструмент, который находит такие совпадения и сокращает ручную проверку до просмотра подозрительных пар. Решение о плагиате при этом остаётся за преподавателем.

Для этого нужно решить следующие задачи:

- принимать архив со сдачей, распаковывать его и разбирать файлы по студентам и по типам (исходный код или отчёт), пропуская повреждённые и неподдерживаемые файлы с сообщением об ошибке;
- сравнивать исходный код минимум двумя методами: по последовательности токенов, где имена переменных и функций приведены к единому виду, и по структуре синтаксического дерева (AST), где функции сопоставляются независимо от их порядка в файле. Так переименование переменных и перестановка функций не скрывают копирование;
- поддерживать три языка программирования: Python, C++ и Java;
- для отчётов реализовать собственный конвейер обработки: извлечь текст из DOCX и PDF, нормализовать его (привести к одному регистру, убрать пунктуацию и лишние пробелы), разбить на шинглы (перекрывающиеся фрагменты из фиксированного числа слов), получить из них отпечатки с помощью хеширования и сравнить наборы отпечатков между работами;
- исключать из сравнения шаблонные части: титульные листы, текст задания и код, который автоматически генерирует IDE;
- обрабатывать сдачу пакетом, от сотни файлов за один запуск;
- формировать итоговый отчёт, в котором проценты сходства по коду и по тексту указаны отдельно, и давать открыть любую пару в режиме просмотра рядом (side-by-side) с подсветкой совпадающих фрагментов;
- сделать два интерфейса: командную строку (CLI) и веб-интерфейс;
- порог сходства и выделение пар, которые его превышают;
- оценка от 0 до 100 %;
- проверка качества на размеченных парах с оценкой точности и полноты. Точность показывает, какая доля найденных пар действительно списана, а полнота показывает, какую долю списанных пар программа нашла.

Технологии: Python 3; модули zipfile, tokenize, ast и hashlib; библиотека tree-sitter для разбора кода на C++ и Java; python-docx и PyMuPDF для извлечения текста; argparse для CLI; FastAPI с шаблонами Jinja2 для веб-интерфейса; SQLite для хранения результатов проверок.

На входе: ZIP-архив со сдачей (исходный код на Python, C++ и Java, отчёты в DOCX и PDF), файлы шаблонов для исключения (титульный лист, текст задания), пороги сходства и параметры сравнения в файле config.json.

На выходе: работающая программа с CLI и веб-интерфейсом, которая по архиву со сдачей строит таблицу всех пар работ с отдельными процентами сходства по коду и по тексту и показывает для каждой пары совпавшие фрагменты рядом с подсветкой. Качество проверяется на собственном наборе примеров: прямые копии, копии с переименованием и перестановкой функций, независимые решения.

Состав команды:

Иванов Николай Сергеевич
Каныгин Карен Каренович
Мельниченко Вадим Сергеевич
Миронов Игорь Сергеевич
Савельев Ярослав Валерьевич

Группа: 4516

Ссылка на github: <https://github.com/RickyTickyTally/ADS>